

自分のPCでサクサク動く！

- ローカルLLMの推論速度を上げる方法 -

笹川 尋翔

なぜ「推論速度」が重要なのか？

- 自然に文章を読む速度を維持できない
 - > ストレスを感じさせる
 - 次の指示出しや修正までの時間が短いほど良い
- 1秒間に処理できるトークン数が多い
 - > 並列処理が容易
- AIが繰り返し思考（Chain of Thought）できる
 - > エージェントとしての性能が高くなる

LLMの推論プロセス

1. Prefill（プロンプト処理）


ユーザーが入力したプロンプト全体を読み込み、解析する工程

TransformerモデルのSelf-Attentionにおいて、計算量は $O(n^2)$

2. Decode（逐次生成）

解析結果を基にトークンを1つずつ順番に生成する工程

LLMの推論プロセス



出典: [Prefill and Decode for Concurrent Requests - Optimizing LLM Performance](#)


LLMの推論性能の評価指標

- Prefillの場合: TTFT (Time To First Token)
 - 最初の1トークン目が出るまでの時間
 - 画面に最初の文字が表示されるまでの「待ち時間」
- Decodeの場合: TPS (Tokens Per Second)
 - 1秒あたりに生成されるトークン数
 - 最初の文字が出た後の「書き込み速度」

Prefillの高速化: FlashAttention

- メモリへの読み書きを減らすことで高速化
- Tiling (タイリング)
 - 行列をブロックに分割して計算し、SRAMを効率的に活用
- Recomputation (再計算)
 - 逆伝播時に中間結果をメモリに保存せず「計算し直す」
 - メモリからの読み込み待ちがなくなり、速くなる

Prefillの高速化: FlashAttention



- HBM（緑色のブロック）：
容量が大きい
読み書きの速度が遅い
- SRAM（オレンジ色のブロック）：
読み書きの速度が非常に速い
容量が極めて小さい

出典: [ELI5: FlashAttention](#)

Prefillの高速化: Prompt Caching

- システムプロンプトなどの共通の入力部分の計算結果を再利用
- キャッシュヒット時: TTFTがミリ秒単位に

Decodeの高速化: Speculative Decoding


- 小さなモデルを使用して初期の予測を行う
-> その結果を大きなモデルが検証

ドラフトモデル（小さなモデル）：高速に動作

ターゲットモデル（大きなモデル）：高精度だが低速

1. Drafting: ドラフトモデルがトークンを生成
2. Verification: ターゲットモデルがトークンを検証
3. Acceptance: ターゲットモデルの判断と一致したトークンを承認

Decodeの高速化: Speculative Decoding



出典: [Speed Up LLM Inference with Speculative Decoding](#)

Decodeの高速化: KV Cache Quantization

KVキャッシュを低ビットに圧縮して保存

Decode時: メモリからデータを読み出す速度がボトルネックに

KVキャッシュを量子化すると、メモリのI/O待ち時間が減少

共通技術: Weight Quantization

モデルのパラメーターの精度を下げ、メモリ消費量を減らす


16ビットで保持 -> 4ビットなどに圧縮

共通技術: Weight Quantization

フォーマット	特徴	主な用途
GGUF	CPU + GPU で動作 扱いやすい	Mac、グラボがないPC
EXL2	GPU向け bit数を細かく指定	高速なレスポンスを求める場合
AWQ / GPTQ	GPU向け 広く普及している	サーバー構築やGPUによる推論

共通技術: Weight Quantization

- 合計メモリサイズを考慮すると、4ビット量子化が最も精度が高い



比較表

改善項目	技術	メリット	デメリット
TTFT	FlashAttention Prompt Caching	待ち時間を短縮	なし
TPS	Speculative Decoding	トークン生成を高速化	メモリ消費量が増える
メモリ占有量	Weight Quantization	巨大なモデルが動く	精度が低下
メモリ消費量	KV Cache Quantization	長文を扱えるようになる	精度が低下

まとめ

- 待ち時間を減らしたい
 - FlashAttention の有効化と Prompt Caching の活用
- 生成速度を上げたい
 - Speculative Decoding や KV Cache Quantization
- メモリが足りない・手軽に試したい
 - GGUF 形式での4ビット量子化

参考文献

- T. Dettmers and L. Zettlemoyer, "The Case for 4-bit Precision: k-bit Inference Scaling Laws," in Proceedings of the 40th International Conference on Machine Learning, vol. 202, 2023, pp. 7750-7774.