Gemma 3 → 4で何が変わったのか？
- いつでも使えるローカルLLMの話 -

笹川 尋翔

Gemma 4が登場

- 2026年4月、Gemma 4の登場によりローカルAI環境が激変
- 2025年リリースのGemma 3から約1年でメジャーアップデート
- 性能と機能の両方が改善され、実用性が向上

改善点1: コンテキスト長が増加

- Gemma 3: 最大128,000トークンのコンテキストを導入
- Gemma 4: 最大256,000トークンに増加
- 技術仕様書、数万行のコード、長い議事録を一度に処理可能
- RAGなしでも、コンテキスト内で高い正解率を維持
- 小型モデル（E2B/E4B）でも128Kという高い水準を確保

改善点2: 音声、動画をネイティブで処理可能に

- Gemma 3: テキストに加え、画像入力をネイティブに理解
- Gemma 4: 音声、動画へのネイティブ対応を実現
- 動画内の時間的な変化や因果関係を論理的に説明可能
- 「見て、聴いて、話す」ローカルAIエージェントの基盤に

改善点3: Tool Useにネイティブで対応

- Tool Use
  - 外部の道具（プログラム、APIなど）を自ら活用し、タスクに取り組む機能
- Function Calling（関数呼び出し）とも呼ばれる
- タスクを自律的に行うエージェント型AIとしての性能が向上

改善点4: 思考（Thinking）が可能に

- Chain-of-Thought（CoT）により論理的なミスが減少

	Gemma 4 31B	Gemma 4 26B A4B	Gemma 3 27B
MMLU Pro	85.2%	82.6%	67.6%
AIME 2026	89.2%	88.3%	20.8%
LiveCodeBench v6	80.0%	77.1%	29.1%
GPQA Diamond	84.3%	82.3%	42.4%

改善点5: 推論速度が向上

- Gemma 4 26B A4BはMoE（Mixture of Experts）を採用
- 推論時に活性化するのは約4Bのみ
- Gemma 3 27Bを超える知能を、より低負荷で提供
- 32GB以上のメモリを搭載したMacBook Proで快適に動作

改善点6: 商用利用が可能に

- Gemma 3: Gemma Terms of Use（独自ライセンス）
  - ライセンスの継承（Share-alike）が必要
  - 商用利用が制限
- Gemma 4: Apache 2.0ライセンス
  - Open Source Initiative （OSI）が承認
    - 法的リスクが低い
  - 商用利用が可能

Gemma 3 27B vs Gemma 4 26B A4B

	Gemma 4 27B	Gemma 4 26B A4B
コンテキスト長	128,000	256,000
マルチモーダル対応	テキスト、画像	テキスト、画像、音声、動画
Tool Use	プロンプトで対応	ネイティブで対応
Thinkingモード	利用不可	利用可
アーキテクチャ	Dense	Mixture of Experts
ライセンス	独自ライセンス	Apache 2.0ライセンス

活用例: 検索機能が付いたSlack Bot

```python
def search_web(query: str) -> str:
    """
    インターネットで最新情報を検索し、結果のリストを返します。
    """
    try:
        with DDGS() as ddgs:
            results = [r for r in ddgs.text(query, max_results=5)]
        return json.dumps(results, ensure_ascii=False)
    except Exception as e:
        return f"Search Error: {e}"
```

活用例: 検索機能が付いたSlack Bot

```python
def visit_website(url: str) -> str:
    """
    指定されたURLのウェブサイトにアクセスし、そのテキスト内容を取得します。
    """
    try:
        response = requests.get(url, timeout=10)
        response.raise_for_status()
        soup = BeautifulSoup(response.text, 'html.parser')

        for script_or_style in soup(["script", "style", "header", "footer", "nav"]):
            script_or_style.decompose()
        text = soup.get_text(separator=' ', strip=True)
        return text[:5000]
    except Exception as e:
        return f"Error visiting website: {e}"
```

活用例: 検索機能が付いたSlack Bot

スレッド

Hiroto Sasagawa 日曜日 21:44
@Gemma明日の天気

3 件の返信

Gemma アプリ 日曜日 21:44
@Hiroto Sasagawa
申し訳ありませんが、お住まいの地域（市区町村など）を教えていただけますでしょうか？
場所をご指定いただければ、明日の天気予報をお調べいたします。

Hiroto Sasagawa 日曜日 21:45
@Gemma東京都大田区

Gemma アプリ 日曜日 21:46
@Hiroto Sasagawa
東京都大田区の明日（2026年4月27日 月曜日）の天気予報をお伝えします。
明日の天気は**雨**が降る可能性が高く、外出の際は傘を忘れないようにしてください。

- **天気**: 雨（降水確率は80%と高めです）
- **最高気温**: 17℃
- **最低気温**: 14℃

気温は今日に比べると少し下がる見込みですので、体調を崩さないよう暖かくしてお過ごしください。

参考文献

- "Gemma 4 モデルカード". Google AI for Developers. https://ai.google.dev/gemma/docs/core/model_card_4